

5 Streuungsmaße

Streuungsmaße dienen zur Quantifizierung, wie weit auseinander bzw. wie eng zusammen die einzelnen Werte x_i eines Merkmals X liegen. Dafür gibt es verschiedene Konzepte:

- Range
- Mittlere Abweichung
- Varianz
- Standardabweichung = $\sqrt{\text{Varianz}}$

Die Varianz und die Standardabweichung spielen vor allem in der Wahrscheinlichkeitsrechnung und in der Induktiven Statistik eine bedeutende Rolle. Die mittlere Abweichung ist zwar anschaulich, jedoch in der Praxis und Theorie kaum anzutreffen.

5.1 Range

Der Range eines Merkmals X , auch **Spannweite** genannt, ist der Abstand zwischen dem größten und dem kleinsten Merkmalswert:

Range bzw. Spannweite

$$R = \text{Maximalwert} - \text{Minimalwert}$$

Die Bildung des Range setzt ein metrisches Merkmal X voraus. Der Range ist ausreißersensitiv.

Beispiel (Malzbierabsatz). In der Kneipe CRAZY BABY ist an $N = 4$ Tagen der Malzbierabsatz X [Liter] gemessen worden. Die Urliste lautet: 150, 180, 230, 240.



5.2 Mittlere Abweichung

Wie weit sind die einzelnen Werte x_i vom Durchschnitt $\bar{x}$ entfernt?

Beispiel (Fortsetzung).

Der Mittelwert zur Urliste 150, 180, 230, 240 beträgt $\bar{x} = 200$.



$$\begin{aligned}
 \delta &= \text{mittlere Entfernung der Einzelwerte zum Durchschnitt} \\
 &= \frac{|150 - 200| + |180 - 200| + |230 - 200| + |240 - 200|}{4} \\
 &= \frac{|-50| + |-20| + |30| + |40|}{4} \\
 &= 35 \text{ [Liter]}
 \end{aligned}$$



Mittlere Abweichung

$$\delta = \text{mittlere, absolute Entfernung der einzelnen Variablenwerte } x_i \text{ vom Durchschnittswert } \bar{x}. \quad (1)$$

Berechnung bei gegebener

- Urliste:

$$\delta = \frac{1}{N} \sum_{i=1}^N |x_i - \bar{x}|. \quad (2)$$

- Verteilung $h(x)$: Die verschiedenen Variablenwerte seien mit $x_1, \dots, x_m$ bezeichnet.

$$\delta = \sum_{k=1}^m |x_k - \bar{x}| \cdot h(x_k). \quad (3)$$

Bei einer stetigen bzw. klassifizierten Variablen X wählt man für x_k die jeweilige Klassenmitte.

5.3 Varianz

Einziger Unterschied zur mittleren Abweichung δ : Die Abstände werden **quadratisch** gemessen!

Beispiel (Fortsetzung).

Der Mittelwert zur Urliste 150, 180, 230, 240 beträgt $\bar{x} = 200$.



$$\begin{aligned}
 \sigma^2 &= \text{mittlere, quadratisch gemessene Entfernung der Einzelwerte zum Durchschnitt} \\
 &= \frac{(150 - 200)^2 + (180 - 200)^2 + (230 - 200)^2 + (240 - 200)^2}{4} \\
 &= \frac{(-50)^2 + (-20)^2 + 30^2 + 40^2}{4} \\
 &= 1350 \text{ [Liter}^2\text{]}
 \end{aligned}$$



Wir müssen offenbar in den Formeln von δ lediglich den Betrag $| \quad |$ durch Quadrieren $(\quad)^2$ ersetzen.

Berechnung der Varianz bei gegebener

- Urliste:
$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2. \quad (4)$$

- Verteilung $h(x)$: Die verschiedenen Variablenwerte seien mit $x_1, \dots, x_m$ bezeichnet.

$$\sigma^2 = \sum_{k=1}^m (x_k - \bar{x})^2 \cdot h(x_k). \quad (5)$$

Bei einer stetigen bzw. klassifizierten Variablen X wählt man für x_k die jeweilige Klassenmitte.

Die Standardabweichung σ besitzt die gleiche Einheit, wie die Variable X selbst. Die Varianz σ^2 weist das Quadrat der Einheit von X auf.

5.4 Standardabweichung

Man beachte, dass bei der Varianz die Abweichungen verzerrt gemessen werden. Werte über 1 werden durch Quadrieren größer, Werte unter 1 werden kleiner. Diesen Effekt kann man gewissermaßen im Nachhinein etwas korrigieren, wenn man von der Varianz die Wurzel zieht.

Standardabweichung

$$\sigma = \sqrt{\text{Varianz}} = \sqrt{\sigma^2} \quad (6)$$

Zudem besitzt die Standardabweichung wieder unquadrierte Einheiten.

Beispiel (Fortsetzung). Aus $\sigma^2 = 1350 \text{ [Liter}^2\text{]}$ erhält man die Standardabweichung

$$\begin{aligned} \sigma &= \sqrt{\text{Varianz}} = \sqrt{\sigma^2} = \sqrt{1350} \\ &= 36.74 \text{ [Liter]}. \end{aligned}$$



Man beachte, dass die Standardabweichung σ nicht das gleiche wie die mittlere Abweichung δ ist:


$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2} \quad \neq \quad \frac{1}{N} \sum_{i=1}^N \sqrt{(x_i - \bar{x})^2} = \frac{1}{N} \sum_{i=1}^N |x_i - \bar{x}| = \delta$$

Beispiel (Edelsteine). Arthur hat zu den letzten $N = 6$ Tagen ermittelt, wie viele Edelsteine X in seiner Mine gefunden worden sind. Die Urliste lautet:


8, 8, 8, 26, 275, 275.



Beispiel (Eisdiele). Bei den Einwohnern von Deppbach hat man ermittelt, wie oft X sie im letzten Monat eine Eisdiele aufgesucht haben.



Beispiel (Äpfel). Bei der letzten Lieferung mit Äpfeln hat man folgende Verteilung des Gewichtes X [g] ermittelt:



Beispiel (Umsätze). Bei einem Kaufhaus ist bezüglich der Umsätze X [T€] bekannt:

- An jedem Tag wurden mindesten 20 000, aber nicht mehr als 180 000 Euro eingenommen.
- An 30% der Tage lag der Umsatz über 100 000 Euro.
- An 80% der Tage lag der Umsatz unter 120 000 Euro.
- An 10% der Tage lag der Umsatz nicht über 60 000 Euro.



5.5 Optimale Lageparameter

Mit welcher Zahl c kann man die Zahlen $x_1, \dots, x_N$ möglichst gut und repräsentativ darstellen?


Für "möglichst gut" gibt es keine universell richtige Lösung, jedoch verschiedene Konzepte:

❶ Absolute Abweichungen

Man wählt die Konstante c so, dass sie im Schnitt einen möglichst geringen Abstand zu den einzelnen Messwerten $x_1, \dots, x_N$ aufweist:


$$\min_c \frac{1}{N} \sum_{i=1}^N |x_i - c|.$$

Bewegt man c um "1 mm" nach links,



so verlängert sich zwar der rechte Balken um 1 mm, dafür aber verkürzen sich die 3 linken Balken um je 1 mm. Die Summe aller 4 Abweichungen verringert sich dadurch um 2 mm.

Bewegt man c um "1 mm" nach rechts,



so verlängern sich zwar die 2 rechten Balken um je 1 mm, dafür aber verkürzen sich die 2 linken Balken um den gleichen Betrag. Die Summe aller 4 Abweichungen bleibt unverändert.

Wenn links und rechts gleich viele Balken auftreten, ist die Summe aller Abweichungen minimal. Daher ist der optimale Wert c ein **Median**:

$$c = x_{me}.$$

Das Optimierungsproblem besitzt manchmal verschiedene, gleich gute Lösungen. In diesem Fall gibt es auch mehrere Mediane.

❷ Quadrierte Abweichungen

Nun werden die Abweichungen quadratisch gemessen und bezüglich c minimiert:

$$\min_c \frac{1}{N} \sum_{i=1}^N (x_i - c)^2.$$

Dieses Optimierungsproblem besitzt als einzige Lösung das **arithmetische Mittel**:

$$c = \bar{x}.$$

Bei quadratisch gemessenen Abweichungen entspricht der minimale, mittlere Abstand der Varianz:

$$\text{Varianz} = \sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2 \leq \frac{1}{N} \sum_{i=1}^N (x_i - c)^2 \quad \text{für alle } c.$$